Predikcija religija država

Ilija Vitošević E2 86/2025, Nikola Magdić E2 52/2025

Definicija problema

Potrebno je pronaći skup podatak koji opisuje države i njihove zastave kroz geopolitičke karakteristike i atribute zastava. Potom, treba razviti sistem za predikciju religije država na osnovu pomenutog skupa podataka uz evaluaciju različitih klasifikacionih algoritama i analizu značajnih pojedinih atributa.

Motivacija problema rešavanog u projektu

Analizom simbola i boja na zastavama, u kombinaciji sa geopolitičkim podacima, može se ustanoviti u kojoj meri vizuelni identitet države opisuje njen kulturni i religijski profil. Takva analiza ima primene u oblastima politologije, antropologije i međunarodnih odnosa.

Relevantna literatura

Feature Selection Techniques to Predict the Religion of a Country from Its Flag [link – potrebno je preuzeti dokument i u sadržaju pronaći hiperlink ka 191. strani gde se ovaj rad nalazi u datom zborniku radova]

- **Cilj rada:** Ispitivanje efikasnosti različitih tehnika selekcije atributa u predikciji religije države na osnovu vizuelnih i simboličkih karakteristika zastava i države; Pokazivanje da redukcija dimenzionalnosti i izbor relevantnih atributa može da poboljša tačnost modela i smanji vreme treniranja.
- **Opis skupa podataka:** Koristi se isti skup podataka koji će se koristiti u našem projektu, videti o tome ovde.
- **Opis metodologije:** Primena Feature Selection tehnika (Select From Model i Lasso) da bi se smanjila dimenzionalnost podataka. Rezultat procesa selekcije obeležja koristi se u klasifikatorima zasnovanim na stablima (Decision Tree, Random Forest, Extra Tree).
- **Način evaluacije:** Rezultati tačnosti klasifikatora (accuracy) dobijeni korišćenjem obeležja izabranih pomenutim tehnikama upoređeni su sa rezultatima tačnosti dobijenim korišćenjem svih obeležja bez ikakve tehnike selekcije.
- **Rezultati:** Feature selection je uglavnom dovela do poboljšanja tačnosti kod većine pomenutih algoritama. Najbolji klasifikator jeste Random Forest sa Select from Model Feature selekcijom sa tačnošću od 0,691.
- **Zaključak:** Planira se da se koristi Random Forest klasifikator uz Lasso Feature Selection tehniku, ali će mera evaluacije biti f1-score umesto accuracy. Značajno je što će se raditi nad istim skupom podataka.

Estimating The Religion of Countries According to Shapes of The Flags Using Support Vector Machines and Kernel Methods [link]

- **Cilj rada:** Ispitivanje mogućnost predikcije religije države na osnovu vizuelnih i simboličkih karakteristika zastava i države; Poseban fokus je na poređenju različitih kernel metoda i njihovoj efikasnosti u klasifikaciji.

- **Opis skupa podataka:** Koristi se isti skup podataka koji će se koristiti u našem projektu, videti o tome ovde.
- **Opis metodologije:** Koristi se Support Vector Machine za klasifikaciju religija. Kao kernel funkcija korišćene su: Radial Basis Function, Sigmoid, Linear, Polynomial. One omogućavaju mapiranje podataka u višu dimenziju radi lakšeg razdvajanja klasa zarad lakše klasifikacije.
- **Način evaluacije:** Zasnovana je na tačnosti klasifikacije (accuracy). Rezultati za različite kernel funkcije su međusobno upoređivani.
- **Rezultati:** Polynomial, Linear i RBF kernel postigli su 100% tačnost, dok je Sigmoid kernel imao znatno lošije rezultate, sa tačnošću od 30,4%. Izbor kernel funkcije značajno utiče na performanse SVM klasifikatora.
- **Zaključak:** Testiraće se nad SVM-om sa Linear funkcijom za kernel. Koristiće se f1-score kao mera evaulacije umesto accuracy. Značajno je što će se raditi nad istim skupom podataka.

Predicting Life Expectancy in Diverse Countries Using Neural Networks: Insights and Implications [link]

- **Cilj rada:** Razvijanje neuronske mreže koja može da predviđa očekivani životni vek u različitim državama na osnovu socioekonomskih, zdravstvenih i kulturnih atributa s ciljem da se pokaže da MLP mreže mogu uspešno da se koriste za kompleksne društveno-geopolitičke probleme.
- **Opis skupa podataka:** Preuzet je sa sajta Kaggle [link]. Sadrži 2940 uzoraka i 22 atributa. Ključni atributi za rad su: GDP, schooling (broj godina školovanja), HIV/AIDS (uzrok broja smrtnih slučajeva na 1000 živorođenih od 0 do 4 godine starosti), income composition of resources (numerički pokazatelj ekonomskog standarda države), adult mortality (stopa smrtnosti odraslih starosti 15-60 godina na 1000 odraslih), a predviđa se life expectancy kao numerička vrednost.
- **Opis metodologije:** Korišćena je neuronska mreža tipa Multi-Layer Perceptron sa jednim ulaznim, jednim skrivenim (ReLU aktivacija) i jednim izlaznim slojem (linearna aktivacija). Funckija gubitka je MSE. Analiza značajnih atrbuta rađena je putem SHAP vrednosti.
- **Način evaluacije:** Podaci su podeljeni na test i trening skup. Validacija je rađena kroz cross validation, a evaluacija kroz mere kao što su: MAE i RMSE.
- **Rezultati:** Model je pokazao visoku tačnost (99,27%) u predikciji životnog veka i da neuronske mreže mogu da daju pouzdane rezultate u predikciji društvenih fenomena baziranih na tabelarnim podacima.
- **Zaključak:** Pošto se ovaj tip neuronske mreže može primeniti dobro nad tabelarnim podacima koje i mi imamo, koristićemo ovaj pristup, uz izmene koje su neophodne, jer je u ovom radu u pitanju regresioni problem, a kod nas klasifikacioni. Tako će izlazni sloj imati SoftMax aktivaciju, funkcija gubitka biće Cross-Entropy Loss, a evaluacija će ići kroz f1-score.

Skup podataka [link]

Skup podataka sadrži 30 kolona i 194 reda. Nema nedostajućih vrednosti. Redovi predstavljaju opise država opisane kroz podatke iz kolona. Neke od značajnijih kolona za opis države jesu njen naziv, kontinent na kome se nalazi, veličina populacije i dominantna religija koja će se predviđati. Religija ima sledeće klase: katoličanstvo, ostali Hrišćani, islam, budizam, hinduizam, etničke vere, marksizam i ostalo. Odnos klasa je sledeći: ostali Hrišćani 30.93%, katoličanstvo 20.62%, islam 18.56%, etničke vere 13.92%, marksizam 7.93%, budizam 4.12%, hinduizam 2.06% i ostali 2.06%. Religije su u skupu

podataka već izražene ciframa od 0 do 7. Značajne kolone za opis zastave jesu da li se zastava sastoji od horizontalnih ili vertikalnih pruga, koliko boja postoji, koje su, da li ima nekih simbola poput sunca, zvezde, krsta ili meseca.

Predložena metodologija

Koristiće se Random Forest i Support Vector Machine klasifikacioni algoritmi na bazi prva dva rada. Na bazi trećeg rada praviće se troslojna neuronska mreža već opisana u zaključku tog dela. Analiza značajnih atrbuta biće urađena putem SHAP vrednosti. Ulazni parametri su sadržani u skupu podataka, naravno, bez kolone religija koju je potrebno odrediti, što će zapravo biti izlazni parameter iz pomenutih mehanizama zaključivanja.

Metod evaluacije

Koristiće se podela na trening i test skup u odnosu 85-15, gde će se kroz trening skup raditi 5-fold unakrasna validacija zbog malog broja instanci u skupu podataka. Težiće se izboru najboljih hiperparametara pred proveru na test skupu podataka. Podela će biti stratifikovana da bi se očuvao odnos pojavljivanja religija u trening i test skupu. Kao metrika evaluacije koristiće se f1-score zbog neujednačenosti raspodele klasa religija koje predviđamo.